Análisis temporal, visualización y optimización de consultas para anticipar la demanda de un servicio de streaming

Julián Andrés Solano Ledesma
Programa de Ingeniería Industrial, Facultad de Ingeniería
Corporación Universitaria del Huila (CORHUILA)
Neiva, Colombia

***Resumen*—Este trabajo analiza el interés del público en Spotify como aproximación a la demanda de un servicio de streaming, con el fin de orientar decisiones de capacidad. Se usó una serie real de 3 926 días de visitas al artículo de Spotify en Wikipedia, agregada por mes y suavizada con una media móvil de 12 meses. La tendencia subió de 3 611 a 9 730 visitas diarias entre 2016 y 2022 y bajó a 3 877 en 2026. La estacionalidad va de +10,5 % en diciembre a −12,7 % en junio, y la temporada alta superó a la baja en 8 de 11 años. Además, se optimizó una consulta SQL sobre 2 000 000 de eventos sintéticos: reescribir el filtro y crear un índice de cobertura la hizo 6,2 veces más rápida, mientras que un índice simple la hizo el doble de lenta.**

***Palabras clave*—análisis de series de tiempo, estacionalidad, media móvil, visualización de datos, optimización de consultas, SQL.**

I. Introducción

Un servicio de streaming debe decidir cuándo reforzar la capacidad de sus servidores y cuándo hacer mantenimiento. Decidir sin conocer el comportamiento de la demanda en el tiempo lleva a degradar el servicio en temporada alta o a pagar capacidad ociosa. Este trabajo continúa el caso de estudio del curso, centrado en Spotify, y responde dos preguntas: ¿cómo evoluciona el interés del público y qué patrón estacional tiene?, y ¿cómo consultar ese indicador de forma eficiente cuando los datos crecen?

El conjunto de datos del caso no tiene fechas, así que la dimensión temporal se tomó de las visitas al artículo *Spotify* de Wikipedia en inglés, publicadas por la API de Wikimedia [1]. La actividad en Wikipedia se ha usado como señal del interés del público, por ejemplo para anticipar la taquilla de películas [2].

II. Métodos

A. Serie temporal

La serie tiene 3 926 observaciones diarias, del 1 de enero de 2016 al 30 de septiembre de 2026, sin valores nulos. Se cargó en pandas con la fecha como índice y se agregó por mes con *resample* [3]. Se analizó el promedio diario de cada mes, para que los meses cortos no parezcan más bajos solo por tener menos días.

La tendencia se estimó con una media móvil de 12 meses centrada (2×12). Al abarcar un año completo, los meses altos y bajos se compensan [4]. La estacionalidad se midió dividiendo cada mes entre su tendencia y tomando la mediana por mes de calendario, una variante robusta de la descomposición clásica [4]. También se comparó la mediana diaria de la temporada alta (noviembre–abril) con la de la baja (mayo–octubre).

B. Visualización

Se construyeron dos gráficos con Matplotlib [5]: líneas para la evolución y barras para la comparación, según el objetivo de cada uno [6]. Las longitudes sobre una escala común se comparan con más precisión que los ángulos o las áreas [7]. Ambos ejes empiezan en cero, porque en barras la longitud debe ser proporcional al valor [8], y cada título expresa la conclusión.

C. Optimización de la consulta

Para medir el rendimiento se usó una tabla de 2 000 000 de eventos de reproducción (2024–2025), **sintética** y con semilla fija, calibrada con el conjunto de datos de Kaggle [9] y con la estacionalidad anterior. El indicador es las horas escuchadas por mes en la temporada alta de noviembre de 2024 a abril de 2025, que abarca 524 910 filas (26 %). Se usó SQLite [10]. Cada versión de la consulta se ejecutó 5 veces y se tomó la mediana, se registró su plan de ejecución y se comprobó que todas devolvieran el mismo resultado.

```
-- Antes (y suma por mes en Python)
SELECT * FROM reproduccion
WHERE strftime('%Y-%m', fecha_hora)
  BETWEEN '2024-11' AND '2025-04';

-- Después
CREATE INDEX idx_c3_cubre ON reproduccion
  (fecha_hora, segundos_escuchados);
SELECT substr(fecha_hora,1,7) AS mes,
  ROUND(SUM(segundos_escuchados)/3600.0,1) AS horas
FROM reproduccion
WHERE fecha_hora >= '2024-11-01'
  AND fecha_hora < '2025-05-01'
GROUP BY mes ORDER BY mes;
```

III. Resultados

A. Tendencia

La media móvil sube de 3 611 visitas diarias (julio de 2016) a un máximo de 9 730 (julio de 2022) y baja a 3 877 (marzo de 2026), cerca del nivel de 2016–2017 (Fig. 1). El pico de octubre de 2022 es atípico: no se repite en ningún otro año.

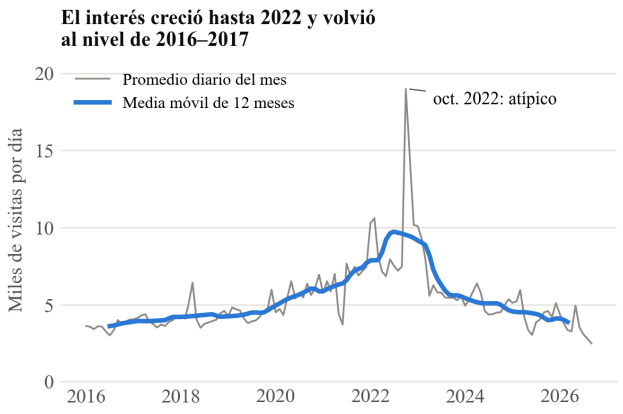


Fig. 1. Evolución del interés en Spotify: promedio diario de visitas por mes y media móvil de 12 meses, enero de 2016 a septiembre de 2026. Elaboración propia con datos de [1].

B. Estacionalidad

La Tabla I muestra un patrón anual: los meses de noviembre a abril suelen estar sobre la tendencia, y los de mayo a octubre, por debajo. Junio y agosto no superaron su tendencia en ningún año medido.

TABLA I
EFECTO TÍPICO DE CADA MES SOBRE LA TENDENCIA

Mes	Efecto	Años sobre la tendencia
Diciembre	+10,5 %	8 de 10
Abril	+8,7 %	6 de 9
Marzo	+7,9 %	6 de 10
Junio	−12,7 %	0 de 9
Julio	−11,2 %	2 de 10
Agosto	−6,7 %	0 de 10

La temporada alta superó a la baja en 8 de 11 años (Fig. 2), pero el patrón no es universal: 2022 fue un empate (7 431 frente a 7 428 visitas), y en 2020 y 2021 ganó la baja. La diferencia de 2023 (+66,6 %) está inflada, porque esa temporada incluye los meses posteriores al pico atípico. La brecha creció en las tres últimas temporadas: +16,8 %, +27,6 % y +32,0 %.

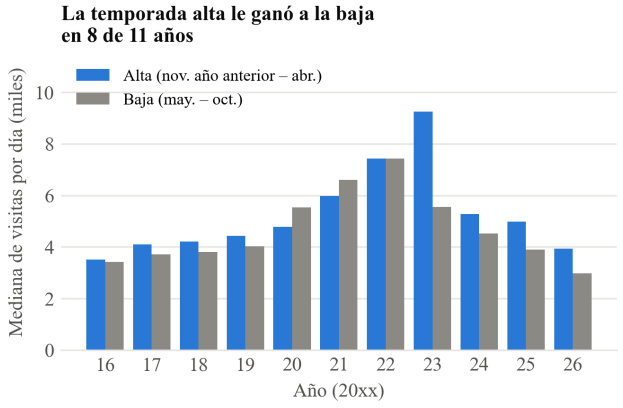


Fig. 2. Mediana de visitas diarias en temporada alta y baja, por año. El año 2016 no incluye noviembre y diciembre de 2015, y la temporada baja de 2026 llega hasta septiembre. Elaboración propia con datos de [1].

C. Rendimiento de la consulta

La Tabla II resume la medición. Las cuatro versiones devolvieron el mismo resultado. Los tiempos corresponden al equipo usado; lo que se puede generalizar es la proporción entre versiones.

TABLA II
RENDIMIENTO DE LAS VERSIONES DE LA CONSULTA

Versión	Tiempo (ms)	Mejora	Filas	Plan
Antes: SELECT *, función y suma en Python	1 754	—	524 910	SCAN
Rango y GROUP BY, sin índice	558	×3,1	6	SCAN
Rango e índice simple	3 410	×0,5	6	SEARCH (índice)
Después: rango e índice de cobertura	281	×6,2	6	SEARCH (cobertura)

IV. Discusión

Para el caso, los meses de noviembre a abril son candidatos a reforzar la capacidad, y los de junio a agosto, a concentrar los mantenimientos. Sin embargo, las visitas a Wikipedia miden atención, no reproducciones, y su audiencia en inglés puede no representar a todos los mercados. Por eso el patrón debe confirmarse con datos internos de streaming antes de decidir.

En la consulta, aplicar *strftime* en cada fila impide buscar con un índice; comparar la columna sin transformarla sí permite usarlo [11], y es una de las buenas prácticas del curso, junto con pedir solo las columnas necesarias y medir el antes y el después [12]. El resultado menos intuitivo es que el índice simple empeoró la consulta: encuentra las filas rápido, pero salta a la tabla por cada una de las 524 910, y con una parte tan grande de la tabla esos saltos cuestan más que un recorrido completo [13]. El índice de cobertura, un árbol B [14] que también contiene la columna sumada, elimina esos saltos, a cambio de más espacio y de inserciones más costosas [13].

V. Findings

The 12-month moving average shows a clear long-term trend: it rose from about 3,600 daily views in 2016 to a peak of about 9,700 in mid-2022, and then fell to about 3,900 by early 2026, close to its 2016–2017 level. The series also has an annual seasonal pattern: December is typically 10.5% above the trend and June 12.7% below it, and August stayed below the trend in all 10 years measured. The evolution chart shows the monthly average together with its moving average, which separates this long-term rise and fall from the monthly noise and from an atypical peak in October 2022. The comparison chart shows the median daily views of the high season (November–April) against the low season (May–October), and the high season won in 8 of 11 years, with a tie in 2022 and the opposite result in 2020 and 2021. Because these figures measure attention on Wikipedia and not actual plays, the pattern should be confirmed with internal streaming data before any capacity decision is made.

VI. Conclusiones

El interés en Spotify creció hasta 2022 y ya volvió al nivel de 2016–2017, con una estacionalidad anual clara aunque no universal. Las escalas honestas y los títulos con conclusión permiten leer ambos hallazgos de inmediato. En la consulta, reescribir el filtro y crear un índice de cobertura la hizo 6,2 veces más rápida con el mismo resultado, y la medición evitó adoptar un índice simple que parecía una mejora y la hacía el doble de lenta.

Referencias

[1] Wikimedia Foundation, "Wikimedia REST API: Pageviews per article," 2026. [Online]. Disponible: https://wikimedia.org/api/rest_v1/ (consultado: 12 oct. 2026).

[2] M. Mestyán, T. Yasseri, and J. Kertész, "Early prediction of movie box office success based on Wikipedia activity big data," *PLoS ONE*, vol. 8, no. 8, Art. no. e71226, 2013, doi: 10.1371/journal.pone.0071226.

[3] Corporación Universitaria del Huila (CORHUILA), "Ciencia de Datos · Semana 11 · Análisis temporal y series de tiempo," Objeto Virtual de Aprendizaje (OVA), Neiva, Colombia, 2026. [Online]. Disponible: https://code-corhuila.github.io/ova-web/2026-B/ciencia-datos/11-week/01-session/

[4] R. J. Hyndman and G. Athanasopoulos, *Forecasting: Principles and Practice*, 3rd ed. Melbourne, Australia: OTexts, 2021, cap. 3. [Online]. Disponible: https://otexts.com/fpp3/

[5] J. D. Hunter, "Matplotlib: A 2D graphics environment," *Comput. Sci. Eng.*, vol. 9, no. 3, pp. 90–95, 2007, doi: 10.1109/MCSE.2007.55.

[6] Corporación Universitaria del Huila (CORHUILA), "Ciencia de Datos · Semana 12 · Visualización de datos," Objeto Virtual de Aprendizaje (OVA), Neiva, Colombia, 2026. [Online]. Disponible: https://code-corhuila.github.io/ova-web/2026-B/ciencia-datos/12-week/01-session/

[7] W. S. Cleveland and R. McGill, "Graphical perception: Theory, experimentation, and application to the development of graphical methods," *J. Amer. Statist. Assoc.*, vol. 79, no. 387, pp. 531–554, 1984, doi: 10.1080/01621459.1984.10478080.

[8] E. R. Tufte, *The Visual Display of Quantitative Information*, 2nd ed. Cheshire, CT, USA: Graphics Press, 2001.

[9] A. Soundankar, "Spotify Global Streaming Data (2024)," Kaggle, 2024. [Online]. Disponible: https://www.kaggle.com/datasets/atharvasoundankar/spotify-global-streaming-data-2024

[10] K. P. Gaffney, M. Prammer, L. Brasfield, D. R. Hipp, D. Kennedy, and J. M. Patel, "SQLite: Past, present, and future," *Proc. VLDB Endow.*, vol. 15, no. 12, pp. 3535–3547, 2022, doi: 10.14778/3554821.3554842.

[11] P. G. Selinger, M. M. Astrahan, D. D. Chamberlin, R. A. Lorie, and T. G. Price, "Access path selection in a relational database management system," in *Proc. 1979 ACM SIGMOD Int. Conf. Manage. Data*, Boston, MA, USA, 1979, pp. 23–34, doi: 10.1145/582095.582099.

[12] Corporación Universitaria del Huila (CORHUILA), "Ciencia de Datos · Semana 14 · Optimización de consultas y métricas (SQL y DAX)," Objeto Virtual de Aprendizaje (OVA), Neiva, Colombia, 2026. [Online]. Disponible: https://code-corhuila.github.io/ova-web/2026-B/ciencia-datos/14-week/01-session/

[13] R. Ramakrishnan and J. Gehrke, *Database Management Systems*, 3rd ed. New York, NY, USA: McGraw-Hill, 2003.

[14] D. Comer, "The ubiquitous B-tree," *ACM Comput. Surv.*, vol. 11, no. 2, pp. 121–137, 1979, doi: 10.1145/356770.356776.